

Guia do modelo e dos dados

B1 V2 - fonte vigente para ML_RAG no MySQL HeatWave | Revisão 23/08/2026

Esta é a fonte normativa da demonstração. Ela apresenta as sete features B1 V2 e o threshold operacional único de 60%.

Finalidade

O laboratório usa o dataset público Credit Card Transactions Fraud Detection, gerado pelo Sparkov e distribuído no Kaggle. São 1.852.394 transações sintéticas de 2019 e 2020; 9.651 têm is_fraud=1 (0,521%). O rótulo é histórico e sintético: nem o rótulo nem o score confirmam fraude de uma pessoa ou empresa.

O HeatWave armazena dados, acelera analytics no cluster, executa o classificador B1 e recupera esta documentação via Vector Store e ML_RAG. Fatos atuais - totais, rankings, casos e resultados de uma rodada - devem ser consultados em SQL nas views públicas; RAG explica método, métricas, limites e governança.

Contrato do modelo B1 V2

Propriedade	Valor aprovado
Handle	febraban_fraud_manual_xgb_b1_final_v2_20260810
Catálogo da aplicação	ML_SCHEMA_febraban.MODEL_CATALOG (proprietário: febraban)
Algoritmo	XGBClassifier para classificação binária
Target histórico	is_fraud; nunca deve ser enviado para uma nova predição
Rotinas	ML_MODEL_LOAD; ML_PREDICT_ROW; ML_PREDICT_TABLE

As sete features efetivamente usadas

Feature	Definição
amount	Valor da compra.
amount_log	LN(1 + amount), para reduzir assimetria de valores altos.
category	Categoria sintética da compra.
transaction_hour	Hora entre 0 e 23.
weekday_number	Dia da semana: segunda-feira=0 e domingo=6.
is_weekend	Indicador de sábado ou domingo, derivado do dia.
customer_merchant_distance_km	Distância entre cliente e estabelecimento sintéticos.

LISTA NORMATIVA COMPLETA DAS SETE FEATURES B1 V2: amount; amount_log; category; transaction_hour; weekday_number; is_weekend; customer_merchant_distance_km. Não há quinta, sexta ou sétima feature implícita: as sete devem estar presentes em toda nova predição.

amount_log deve ser calculado como LN(1 + amount). IDs e timestamp são auditoria, não features. Não envie is_fraud, pois ele é exatamente o alvo que o modelo estima.

Threshold e interpretação correta

Contexto	Threshold / interpretação
Simulação ao vivo	0,60: alerta de risco previsto quando fraud_probability >= 0,60.
Priorização visual	0,85: alerta alto. 0,95: caso crítico. Não confirmam fraude.
Predições históricas B1 V2	0,60: a view pública usa os scores do split de teste do B1 V2.

Comunicação obrigatória: diga 'alerta de risco previsto acima do threshold operacional de 60%'. Nunca diga 'fraude confirmada', nem associe score a culpa, intenção ou bloqueio automático.

Operação da demonstração

A simulação usa fraud_demo.live_transaction_seed para criar eventos coerentes, grava fraud_demo.live_transaction_events e isola cada rodada por run_id. A cada 5.000 eventos, ML_PREDICT_TABLE registra classe, probabilidade e faixa de risco. O dashboard usa consultas analíticas no HeatWave; a interface só declara conclusão quando inserted=scored=50.000.

Em validação E2E de 23/08/2026 com o usuário febraban: 50.000 eventos inseridos, 50.000 classificados, zero falhas de lote, zero falhas de classificação e 612 alertas com score >=60%. Os valores precisam ser tratados como resultado de uma rodada sintética, não métrica universal de produção.

Governança

O laboratório é educacional. Produção requer dados reais validados, segurança, privacidade, monitoramento de drift, avaliação de vieses, revisão humana, trilha de auditoria e política formal para cada limiar. NL_SQL deve aceitar somente SELECT/WITH nas views públicas permitidas; ML_RAG explica documentos e deve exibir citações.